Impacto do Gerenciamento Dinâmico de Contexto na Qualidade Estrutural e Corretude Funcional do Código Gerado por LLMs em Nível de Repositório: Uma Revisão Sistemática da Literatura

Tadeu Jerônimo

Esta revisão sistemática da literatura tem como objetivo investigar os efeitos do gerenciamento dinâmico de contexto na geração automática de código por modelos de linguagem, comparando-o com estratégias de contexto estático. A revisão busca identificar como diferentes formas de gerenciamento de contexto influenciam a qualidade do código produzido, considerando métricas estruturais e a corretude funcional do software.

Planning

O objetivo geral é avaliar, de forma sistemática, o impacto metodológico e empírico do gerenciamento dinâmico de contexto na qualidade estrutural e na corretude funcional do software gerado por modelos de linguagem, confrontando estratégias dinâmicas com baselines de contexto estático e ingestão linear de contexto longo.

Os objetivos específicos são:

OBJ1: Identificar a literatura primária que valide ferramentas ou algoritmos de gerenciamento dinâmico de contexto no desenvolvimento e na refatoração de software agêntico baseado em LLMs.

OBJ2: Descrever os modelos experimentais, ambientes de teste, configurações dos modelos e métricas de qualidade utilizadas.

OBJ3: Comparar os ganhos em métricas estruturais e taxas de sucesso funcional das arquiteturas de contexto dinâmico com os comparadores estáticos.

OBJ4: Sintetizar as evidências, mapear divergências entre RAG e janelas de contexto longas e propor recomendações metodológicas para garantia de qualidade.

PICOC

- **Population:** Grandes Modelos de Linguagem para geração de código
- **Intervention:** Gerenciamento dinâmico de contexto
- **Comparison:** Estratégias de contexto estático
- **Outcome:** Métricas estruturais e a corretude funcional do software produzido
- **Context:** Projetos de Engenharia de Software em nível de repositório

Research Questions

1. RQ: Como o gerenciamento dinâmico de contexto em modelos de linguagem para geração de código altera as métricas estruturais e a corretude funcional do software produzido comparado a estratégias de contexto estático?
2. SQ1: O desempenho das estratégias de contexto dinâmico varia conforme a classe do modelo de linguagem ou a linguagem de programação envolvida?
3. SQ2: Quais ambientes de avaliação e infraestruturas de teste foram utilizados, e quais demonstraram maior robustez estatística e reprodutibilidade?
4. SQ3: Quais abordagens e parametrizações de contexto dinâmico maximizaram a qualidade não funcional e a corretude funcional em nível de sistema?
5. SQ4: Os benefícios reportados são confirmados em estudos com controle de vazamento de dados, partição temporal, sementes aleatórias e código-fonte disponível?

Keywords and Synonyms

Keyword	Synonyms
Dynamic context management	RAG, adaptive context, adaptive context, agent memory, context engineering, context management, context pruning, context selection, dynamic retrieval, retrieval-augmented generation
Language models for code generation	LLM, code LLMs, language models, large language model
Static context strategies	baseline prompting, basic prompting, fixed context, large context window,

	limited context, long context, single-turn, static context, static prompting, static retrieval
Structural metrics and functional correctness of the produced software	code correctness, code metrics, code quality, functional correctness, maintainability, pass@k, software quality, static analysis, structural metrics, structural quality

Search String

("large language model" OR LLM OR "language models" OR "code LLMs")

AND

("dynamic context" OR "dynamic retrieval" OR "context management" OR "context engineering" OR "context pruning" OR "context selection" OR "adaptive context" OR "retrieval-augmented generation" OR RAG OR "agent memory")

AND

("static context" OR "fixed context" OR "limited context" OR "basic prompting" OR "baseline prompting" OR "static prompting" OR "static retrieval" OR "long context" OR "large context window" OR "single-turn")

AND

("functional correctness" OR "code correctness" OR "pass@k" OR "code metrics" OR "structural metrics" OR "structural quality" OR "code quality" OR "software quality" OR "maintainability" OR "static analysis")

Sources

- ACM Digital Library (http://portal.acm.org)
- IEEE Digital Library (http://ieeexplore.ieee.org)
- ISI Web of Science (http://www.isiknowledge.com)
- Scopus (http://www.scopus.com)

Selection Criteria

Inclusion Criteria:

- IC1: Ser um estudo primário empírico, publicado a partir de 2024, escrito exclusivamente em inglês e com texto integral acessível.
- IC2: Investigar explicitamente modelos de linguagem ou sistemas agênticos aplicados à geração, refatoração, reparo, modificação ou tradução ativa de código-fonte no nível de repositório, múltiplos arq
- IC3: Avaliar técnicas de gerenciamento dinâmico de contexto em comparação empírica direta contra ao menos um baseline de contexto estático.
- IC4: Avaliar a qualidade do código produzido por meio de métricas formais de corretude funcional ou qualidade estrutural e não funcional.

Exclusion Criteria:

- EC1: Ser estudo secundário ou terciário, artigo puramente conceitual, editorial, relatório industrial curto, resumo sem dados completos, publicado antes de 2024, escrito em idioma diferente do inglês
- EC2: Trabalhar de forma restrita ao nível de função única ou snippets isolados, RAG puramente textual sem estrutura de software, PLN geral sem código ou análise estática passiva sem alteração ativa de
- EC3: Não apresentar comparação empírica direta contra um baseline de contexto estático de referência ou ter o gerenciamento de contexto apenas como elemento secundário.
- EC4: Ter a avaliação limitada exclusivamente a métricas de recuperação de informação sem analisar o código gerado, ou constituir publicação duplicada.
- EC5: Constituir publicação duplicada; nesse caso, será mantida a versão mais completa e recente do estudo.

Quality Assessment Checklist

Questions:

- QA1: O estudo disponibiliza código-fonte, scripts de execução, arquivos de configuração, dados, prompts, sementes aleatórias e versões das APIs para permitir a replicação do experimento?
- QA2: O estudo identifica claramente os modelos e baselines estáticos, aplica testes estatísticos adequados para avaliar a relevância das diferenças e realiza experimentos em nível de repositório ou múltiplos arquivos?

- QA3: O estudo adota medidas para prevenir contaminação ou vazamento de dados e avalia a estabilidade e consistência da geração por múltiplas execuções, turnos ou sementes de inferência?
- QA4: O estudo avalia a corretude funcional do código gerado por meio de testes executáveis?
- QA5: O estudo analisa atributos não-funcionais e estruturais do software ou reporta métricas de eficiência computacional, custo ou latência associadas ao gerenciamento dinâmico de contexto?

Answers:

- Yes
- Partially
- No

Data Extraction Form

- [DQ1] DE1: Identificador do estudo
- [DQ1] DE2: Autores
- [DQ1] DE3: Ano de publicação
- [DQ1] DE4: País do estudo
- [DQ1] DE5: Veículo de publicação
- [DQ1] DE6: Tipo de publicação
- [DQ2] DE7: Modelo, versão, tamanho e classe do LLM
- [DQ2] DE8: Granularidade do código, linguagens, benchmark e amostra
- [DQ3] DE9: Técnica de gerenciamento dinâmico de contexto
- [DQ3] DE10: Estratégia baseline de contexto
- [DQ4] DE11: Ambiente e infraestrutura de avaliação
- [DQ4] DE12: Configuração experimental e mecanismos de feedback
- [DQ5] DE13: Métricas e resultados funcionais
- [DQ5] DE14: Métricas de qualidade do software e eficiência
- [DQ6] DE15: Artefatos de reprodutibilidade
- [DQ6] DE16: Rigor metodológico e controle de vieses
- [DQ7] DE17: Limitações e ameaças à validade declaradas

Conducting

Digital Libraries Search Strings

ACM Digital Library:

("large language model" OR LLM OR "language models" OR "code LLMs")

AND

("dynamic context" OR "dynamic retrieval" OR "context management" OR "context engineering" OR "context pruning" OR "context selection" OR "adaptive context" OR "retrieval-augmented generation" OR RAG OR "agent memory")

AND

("static context" OR "fixed context" OR "limited context" OR "basic prompting" OR "baseline prompting" OR "static prompting" OR "static retrieval" OR "long context" OR "large context window" OR "single-turn")

AND

("functional correctness" OR "code correctness" OR "pass@k" OR "code metrics" OR "structural metrics" OR "structural quality" OR "code quality" OR "software quality" OR "maintainability" OR "static analysis")

IEEE Digital Library:

("large language model" OR LLM OR "language models" OR "code LLMs")

AND

("dynamic context" OR "dynamic retrieval" OR "context management" OR "context engineering" OR "context pruning" OR "context selection" OR "adaptive context" OR "retrieval-augmented generation" OR RAG OR "agent memory")

AND

("static context" OR "fixed context" OR "limited context" OR "basic prompting" OR "baseline prompting" OR "static prompting" OR "static retrieval" OR "long context" OR "large context window" OR "single-turn")

AND

("functional correctness" OR "code correctness" OR "pass@k" OR "code metrics" OR "structural metrics" OR "structural quality" OR "code quality" OR "software quality" OR "maintainability" OR "static analysis")

ISI Web of Science:

("large language model" OR LLM OR "language models" OR "code LLMs")

AND

("dynamic context" OR "dynamic retrieval" OR "context management" OR "context engineering" OR "context pruning" OR "context selection" OR "adaptive context" OR "retrieval-augmented generation" OR RAG OR "agent memory")

AND

("static context" OR "fixed context" OR "limited context" OR "basic prompting" OR "baseline prompting" OR "static prompting" OR "static retrieval" OR "long context" OR "large context window" OR "single-turn")

AND

("functional correctness" OR "code correctness" OR "pass@k" OR "code metrics" OR "structural metrics" OR "structural quality" OR "code quality" OR "software quality" OR "maintainability" OR "static analysis")

Scopus:

("large language model" OR LLM OR "language models" OR "code LLMs")

AND

("dynamic context" OR "dynamic retrieval" OR "context management" OR "context engineering" OR "context pruning" OR "context selection" OR "adaptive context"

OR "retrieval-augmented generation" OR RAG OR "agent memory")

AND

("static context" OR "fixed context" OR "limited context" OR "basic prompting" OR "baseline prompting" OR "static prompting" OR "static retrieval" OR "long context" OR "large context window" OR "single-turn")

AND

("functional correctness" OR "code correctness" OR "pass@k" OR "code metrics" OR "structural metrics" OR "structural quality" OR "code quality" OR "software quality" OR "maintainability" OR "static analysis")

Imported Studies

- **ACM Digital Library:** 456
- **IEEE Digital Library:** 7
- **ISI Web of Science:** 36
- **Scopus:** 106